TRƯỜNG ĐẠI HỌC THÁI BÌNH DƯƠNG

Lập trình cho AI và khoa học dữ liệu

Phân tích dữ liệu hành khách Titanic

Báo cáo dự án A2 02
Tầng Cơ bản · Pandas và trực quan hóa

Lương Công Hoàng Duy — MSSV 240464 — phân công 60%
Lê Nguyễn Gia Bảo — MSSV 240233 — phân công 40%

Ngày hoàn thiện: 14 tháng 10 năm 2026

1 Bài toán và người sử dụng kết quả

Nhóm thực hiện một quy trình phân tích dữ liệu từ đọc CSV, khảo sát, làm sạch đến khám phá và diễn giải. Giảng viên và sinh viên dùng kết quả để học cách so sánh nhóm, chọn mẫu số và xử lý dữ liệu thiếu. Bài chỉ mô tả mẫu Titanic, không huấn luyện mô hình học máy hay dự đoán số phận cá nhân.

Ba câu hỏi theo đề giao

1. Những yếu tố nào liên quan tới khả năng sống sót?
2. Giả thuyết “phụ nữ và trẻ em trước” có được phản ánh trong dữ liệu không?
3. Hạng vé có ảnh hưởng độc lập với giới tính không, hay chỉ là biến trung gian?

Câu 1 khảo sát giới tính, tuổi, hạng vé và gia đình. Câu 2 quy ước trẻ em là tuổi ≤12; nhóm >12 còn gồm thiếu niên. Câu 3 dùng bảng chéo giới tính × hạng vé. “Ảnh hưởng độc lập” được xem xét thận trọng: phân tầng mô tả chưa chứng minh quan hệ nhân quả hoặc cơ chế trung gian.

Khai báo công cụ AI và cách kiểm chứng

OpenAI Codex hỗ trợ tổ chức mã, soạn diễn giải và đối chiếu số liệu. Python, Pandas, NumPy, Matplotlib và Seaborn thực hiện phân tích. Notebook đã chạy 11 ô mã liên tiếp trong kernel mới, không lỗi; 14 nhóm assert kiểm tra nguồn, miền giá trị và mẫu số. Hai thành viên vẫn phải tự chạy lại và giải thích mọi dòng mã khi báo cáo.

2 Nguồn và cấu trúc dữ liệu

Bộ dữ liệu theo đề là Kaggle Titanic, tệp **train.csv**: **891 dòng × 12 cột**, có nhãn Survived. Bài dùng bản CSV đã có trên máy, không khai báo đã tải trực tiếp từ Kaggle trong lần thực hiện này. Không ghép test.csv và không dùng số liệu OpenML 1.309 dòng. Đơn vị quan sát là hồ sơ hành khách, không phải gia đình độc lập. [1, 2]

Trường nguồn	Ý nghĩa	Kết quả info: có mặt / kiểu
PassengerId	Mã hồ sơ; không dùng làm yếu tố giải thích	891 / int64
Survived	1 sống, 0 không sống	891 / int64
Pclass	Hạng vé 1, 2, 3	891 / int64
Name	Tên hành khách; bỏ khỏi bảng phân tích	891 / chuỗi
Sex	Giới tính ghi trong nguồn	891 / chuỗi
Age	Tuổi theo năm; số lẻ ở trẻ nhỏ là hợp lệ	714 / float64
SibSp	Anh chị em hoặc vợ/chồng đi cùng	891 / int64
Parch	Cha mẹ hoặc con đi cùng	891 / int64
Ticket	Mã vé; bỏ khỏi bảng phân tích	891 / chuỗi
Fare	Giá vé theo giá trị ghi trong nguồn	891 / float64
Cabin	Cabin; bỏ khỏi bảng phân tích	204 / chuỗi
Embarked	Cảng lên tàu C, Q hoặc S	889 / chuỗi

Kết quả **shape** là (891, 12). Với Pandas 3.0, info ghi 5 cột int64, 2 cột float64, 5 cột chuỗi; ở Pandas 2.x chuỗi có thể hiện là object. Không có trường ngày tháng. Đề A2-02 cho ngoại lệ dưới 2.000 dòng và xếp tầng Cơ bản; không tạo ngày giả hoặc nhân bản hồ sơ. [1]

Nguồn và điều kiện sử dụng

Trang dữ liệu: kaggle.com/competitions/titanic/data. Điều kiện sử dụng theo quy tắc cuộc thi Kaggle [3]. Không tự gán CC0 hoặc khẳng định quyền phát hành lại. Repo dùng link nguồn thay CSV; người chạy tải tệp theo quy tắc Kaggle. Báo cáo chỉ trình bày dữ liệu tổng hợp, không nêu hồ sơ định danh.

SHA256 bản CSV dùng tính toán:
4a437fde05fe5264e1701a7387ac6fb75393772ba38bb2c9c566405af5af4bd7

3 Khảo sát ban đầu và nhật ký làm sạch

describe cho thấy Age trung vị 28, trung bình 29,70 năm. Fare trung bình 32,20 cao hơn trung vị 14,45, phù hợp phân phối lệch phải; giá lớn không tự động là lỗi. Có 342 người sống và 549 không sống: 342/891 = 38,4%.

Biến	n	TB	ĐLC	Min	Trung vị	Max
Age	714	29,70	14,53	0,42	28	80
Fare	891	32,20	49,69	0	14,45	512,33
SibSp	891	0,52	1,10	0	0	8
Parch	891	0,38	0,81	0	0	6

isna().sum(): Age 177 (19,9%), Cabin 687 (77,1%), Embarked 2 (0,2%); mọi cột còn lại thiếu 0. Có 0 dòng trùng hoàn toàn và PassengerId duy nhất. Không có ô mới thành NaN sau ép kiểu số.

Thao tác và lý do	Ảnh hưởng kiểm tra được
Đọc ô rỗng/? thành NaN để thống nhất thiếu	Giữ 891 dòng; ghi rõ thiếu ở 3 cột
Bỏ trùng để tránh đếm lặp	0 dòng xóa; vẫn 891 dòng
Ép kiểu số, kiểm tra miền trước khi tính	0 ô mới thành NaN; tuổi >0, fare ≥0, thân nhân ≥0
Strip và lowercase sex/embarked để nhóm thống nhất	Sex: 0 nhãn đổi; Embarked: 889 nhãn đổi chữ
Khảo sát ngoại lai Fare bằng IQR	116 dòng >65,6344; giữ nguyên, chưa có bằng chứng sai
Giữ tuổi thiếu trong bảng chính	177 ô thiếu; chỉ 714 dòng vào phân tích tuổi
Giữ Embarked thiếu và Fare=0	2 cảng thiếu không làm mất người; 15 giá vé bằng 0
Bỏ PassengerId, Name, Ticket, Cabin khỏi bản phân tích	Cabin thiếu 77,1%; CSV gốc vẫn giữ nguyên
Thêm family_size và age_group	family_size=SibSp+Parch+1; bảng 891 × 10

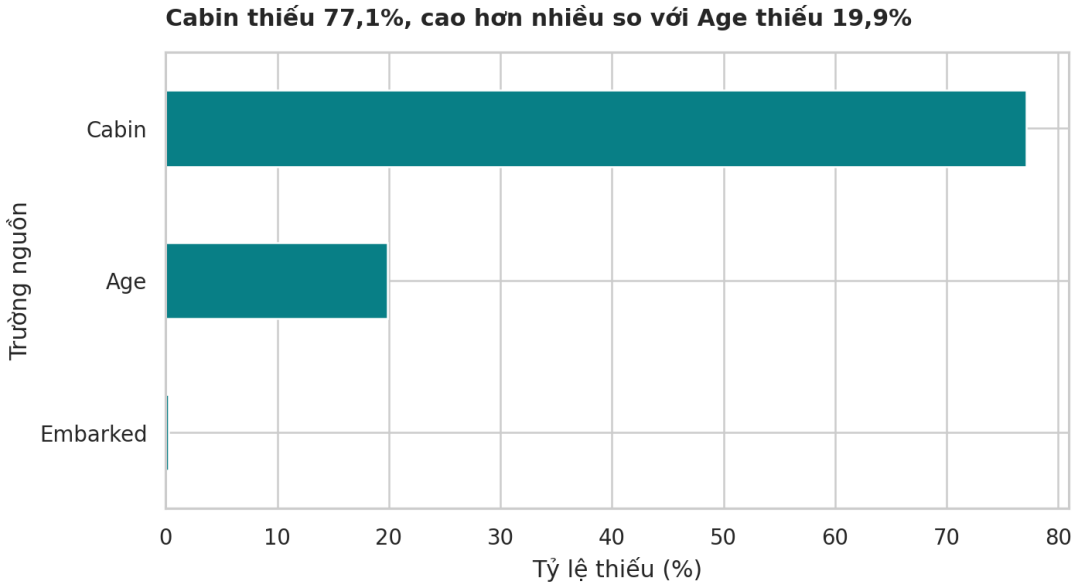
Không xóa dòng theo toàn bộ các cột thiếu. Mỗi câu hỏi chỉ chọn quan sát có dữ liệu liên quan. Không điền số người thân thiếu thành 0 để tránh tạo quy mô giả. Nhật ký đầy đủ và assert nằm trong notebook.

4 So sánh ba chiến lược xử lý Age

Chỉ tiêu	A Tuổi quan sát	B Trung vị chung	C Theo giới × hạng
Hồ sơ phân tích	714	891	891
Số tuổi điền	0	177	177
Tuổi trung bình	29,70	29,36	29,11
Trung vị	28	28	26
Độ lệch chuẩn	14,53	13,02	13,30
Số trẻ ≤12	69	69	69
Sống ở nhóm >12	250/645 (38,8%)	302/822 (36,7%)	302/822 (36,7%)

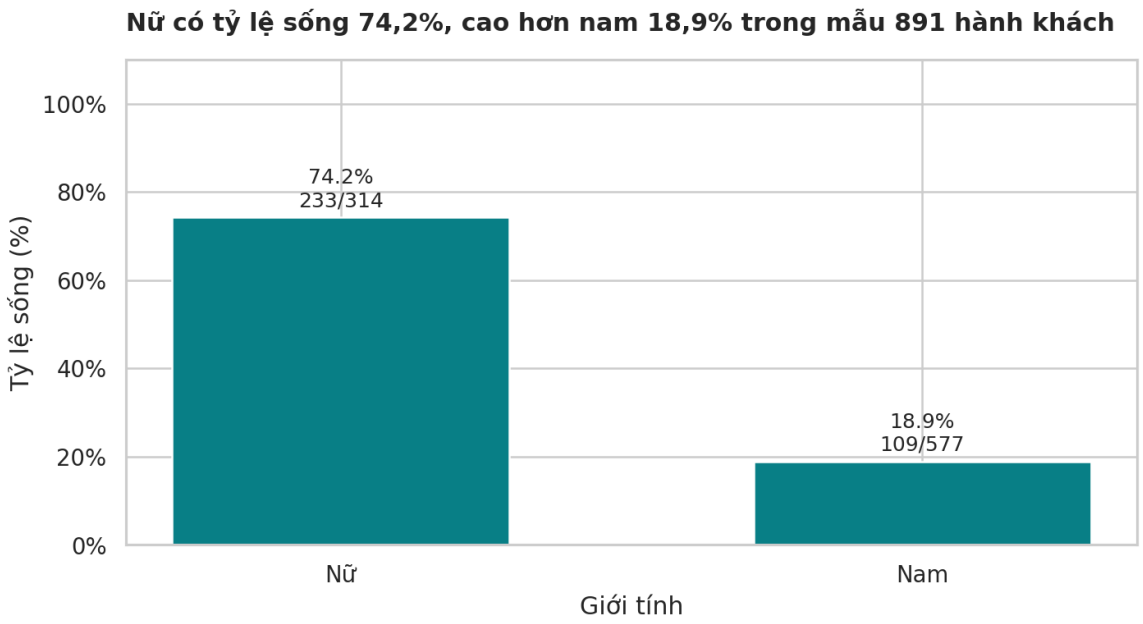
Lựa chọn A cho phân tích chính. A không gán tuổi nhưng giảm mẫu và có thể thiên lệch chọn mẫu. B điền trung vị chung 28; C điền trung vị sex × pclass, dự phòng trung vị chung nếu cần. B/C giữ mẫu nhưng làm giảm độ phân tán, không chứng minh tuổi chính xác hơn. Không dùng Survived để điền tuổi.

Các trung vị đều >12 nên số trẻ giữ 69. Khi điền, mẫu nhóm >12 tăng từ 645 lên 822; không được suy ra mọi hồ sơ thiếu tuổi thực sự >12. Hồ sơ có tuổi có tỷ lệ sống 290/714 = 40,6%, thiếu tuổi 52/177 = 29,4%; vì vậy không mặc định phần thiếu giống phần đã biết.

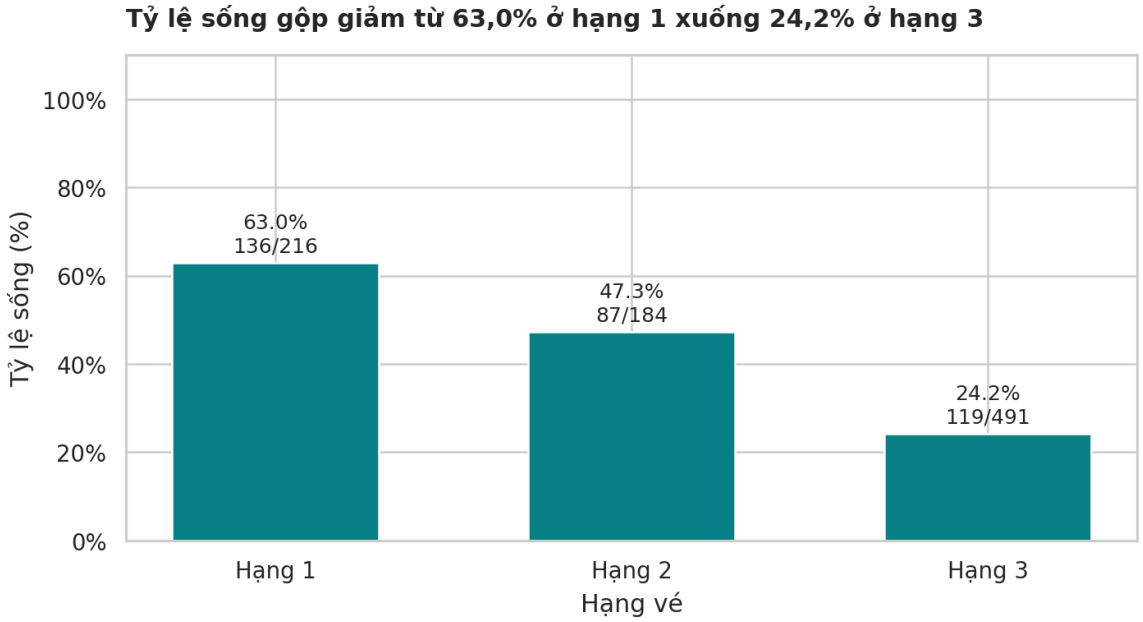


Hình 1. Cabin thiếu 77,1%, không phục vụ trực tiếp ba câu hỏi nên bỏ khỏi bảng phân tích và giữ trong CSV gốc. Quyết định này không có nghĩa Cabin không bao giờ hữu ích; nghiên cứu vị trí trên tàu sẽ cần thiết kế xử lý khác.

5 EDA về giới tính và hạng vé

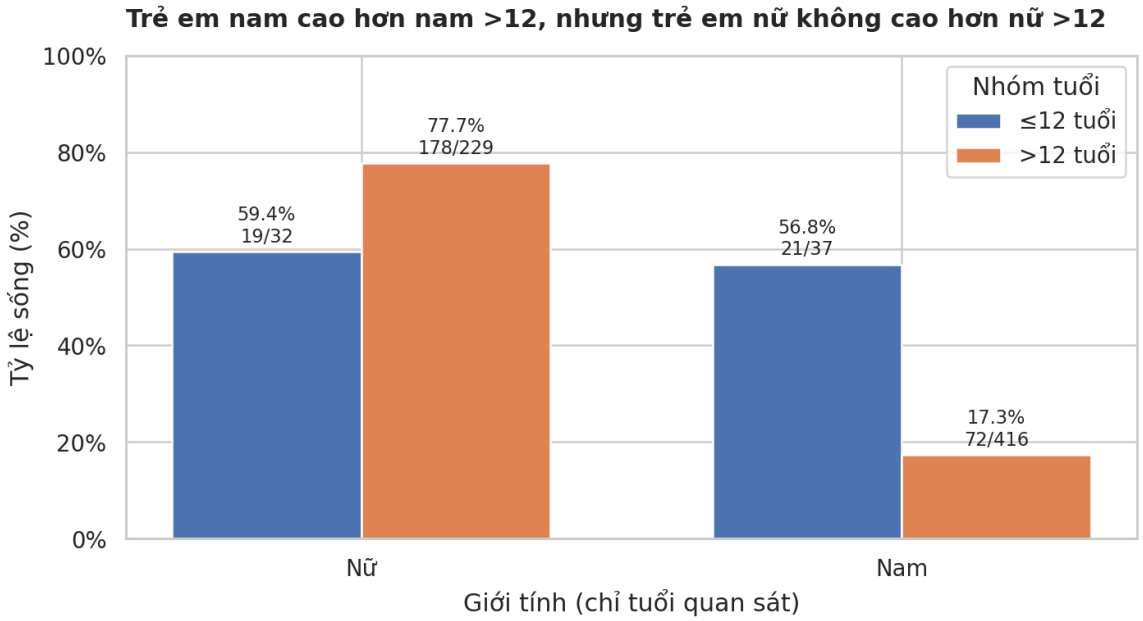


Hình 2. Nữ 233/314 = 74,2%; nam 109/577 = 18,9%, chênh 55,3 điểm phần trăm. Đây là khác biệt tỷ lệ, không chỉ số người sống tuyệt đối. Kết quả hỗ trợ một phần câu 1 và câu 2 nhưng không xác nhận trình tự ưu tiên sơ tán.

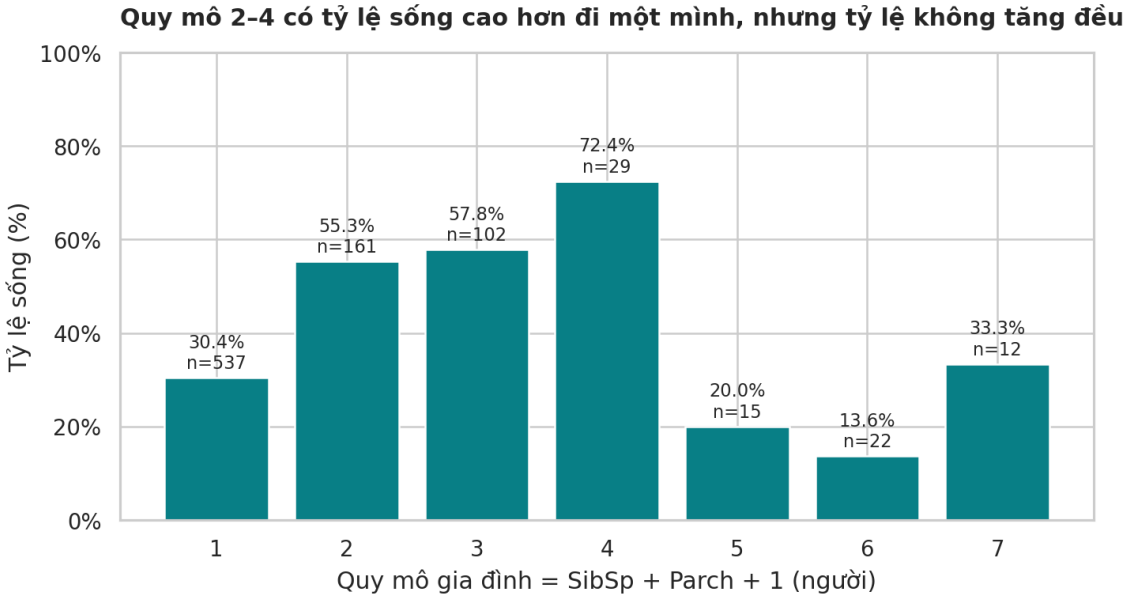


Hình 3. Hạng 1: 136/216 = 63,0%; hạng 2: 87/184 = 47,3%; hạng 3: 119/491 = 24,2%. Khác biệt gộp chưa cho biết liên hệ còn hay mất trong từng giới. Câu 3 phải dùng bảng chéo, không dừng ở hai biểu đồ đơn biến.

5 EDA về tuổi và quy mô gia đình

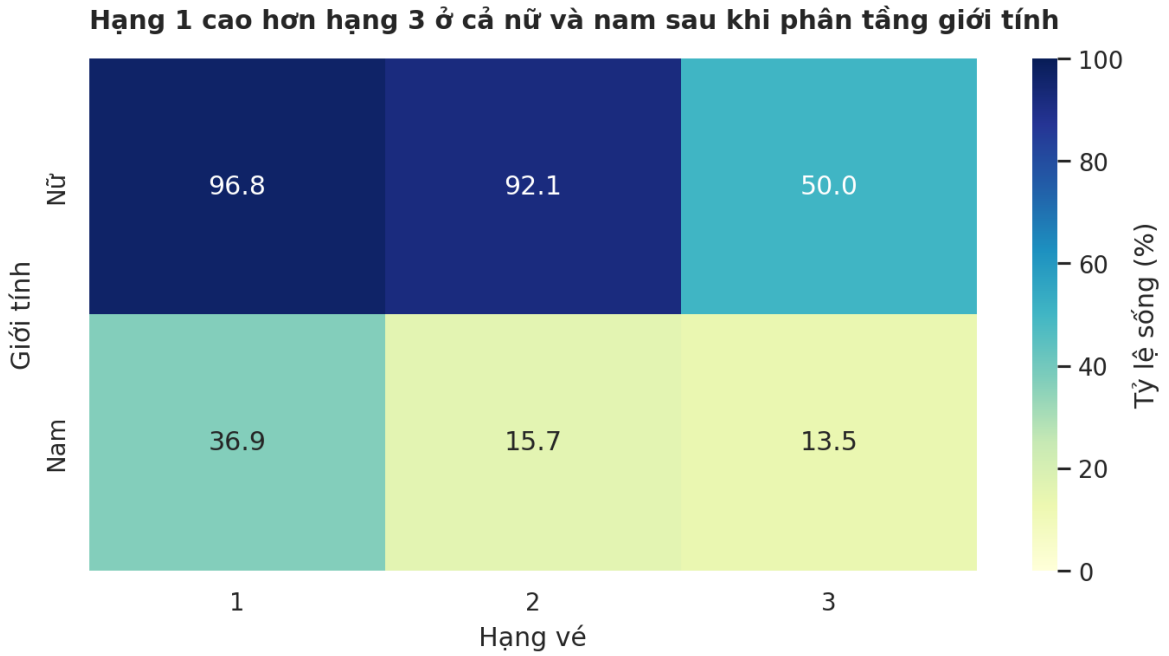


Hình 4. Trong 714 tuổi quan sát, trẻ em nam 21/37 = 56,8% so với nam >12 là 72/416 = 17,3%. Trẻ em nữ 19/32 = 59,4% thấp hơn nữ >12 là 178/229 = 77,7%. Khi gộp giới: trẻ em 40/69 = 58,0%, nhóm >12 là 250/645 = 38,8%. Xu hướng tuổi không đồng nhất ở mọi giới.



Hình 5. Đi một mình 163/537 = 30,4%; quy mô 2–4 là 55,3%–72,4%; quy mô 5 là 3/15 = 20,0%. Nhóm 4 có 65,5% nữ, so với 23,5% ở nhóm đơn; nhóm 5 có 80,0% hạng 3, so với 31,0% ở nhóm 4. Cơ cấu gợi ý cách diễn giải, chưa chứng minh nguyên nhân. Nhóm quy mô 8 (n=6) và 11 (n=7) không vẽ vì n<10, không xóa khỏi dữ liệu.

5 Bảng chéo bắt buộc cho câu hỏi 3



Giới tính	Hạng 1	Hạng 2	Hạng 3
Nữ	91/94 = 96,8%	70/76 = 92,1%	72/144 = 50,0%
Nam	45/122 = 36,9%	17/108 = 15,7%	47/347 = 13,5%

Hình 6 và bảng chéo. Đọc theo hàng: hạng 1 cao hơn hạng 3 trong cả nữ lẫn nam. Tổng sáu ô là 891 người và 342 người sống. Vì chênh lệch vẫn xuất hiện sau phân tầng, liên hệ hạng vé không chỉ là một khác biệt cơ cấu giới tính ở mẫu gộp.

Tuy nhiên, bảng chéo không loại hết ảnh hưởng của tuổi, vị trí trên tàu và những yếu tố không được đo. Nhóm không thực hiện kiểm định suy luận hay mô hình nhân quả. Chưa thể kết luận tác động nhân quả độc lập, độc lập thống kê toàn phần hoặc hạng vé là biến trung gian. Muốn phân tích trung gian cần xác định cơ chế và thứ tự nhân quả, không chỉ quan sát một bảng phần trăm.

Kỹ thuật Pandas và khả năng đối chiếu

groupby + agg tính count, sum và mean của Survived; crosstab tính trung bình theo Sex × Pclass; transform căn chỉnh trung vị nhóm về từng dòng; cut phân nhóm tuổi theo ngưỡng công bố. Mọi tỷ lệ được tính trước khi làm tròn. Các biểu đồ phân phối tuổi và giá vé bổ sung có trong notebook; không có bước huấn luyện mô hình.

6 Ba nhận định có căn cứ và giới hạn

Câu 1. Giới tính, hạng vé, tuổi và gia đình đều có liên hệ mô tả với sống sót: nữ/nam 74,2%/18,9%; hạng 1/3 là 63,0%/24,2%; quy mô 2–4 là 55,3%–72,4%, đi một mình 30,4%. **Giới hạn:** các biến liên quan với nhau, chưa xếp hạng tác động độc lập hoặc suy ra thay đổi một biến sẽ làm tăng cơ hội sống.

Câu 2. Giả thuyết được hỗ trợ một phần: nữ cao hơn nam; trẻ em gộp 58,0% cao hơn >12 là 38,8%. Khi tách giới, trẻ em nam cao hơn nam >12 nhưng trẻ em nữ thấp hơn nữ >12. **Giới hạn:** Age thiếu 19,9%; ngưỡng ≤12 là quy ước; dữ liệu không cho biết ai được cứu trước.

Câu 3. Liên hệ hạng vé còn sau phân tầng: nữ hạng 1/3 là 96,8%/50,0%, nam là 36,9%/13,5%. **Giới hạn:** chưa chứng minh nhân quả độc lập hoặc cơ chế trung gian; không đánh đồng liên hệ có điều kiện với bằng chứng nguyên nhân.

7 Giới hạn chung và phạm vi sử dụng

Mẫu 891 hồ sơ có nhãn không phải toàn bộ hành khách hoặc thủy thủ đoàn. Không suy rộng cho chuyến tàu khác, cứu hộ hiện đại hoặc cá nhân hiện tại. Các hành khách cùng gia đình có thể phụ thuộc nhau; nhóm ít quan sát có tỷ lệ không ổn định. Thiếu thông tin về vị trí, thời điểm và hành động sơ tán. Bỏ định danh khỏi bản phân tích không bảo đảm ẩn danh tuyệt đối. Không dùng tỷ lệ nhóm để tạo định kiến hoặc giảm cơ hội của một người.

8 Công cụ phân công và tài liệu tham khảo

Duy 60%: notebook, làm sạch, câu 1/3, tổng hợp báo cáo. Bảo 40%: nguồn, câu 2, nhãn/mẫu số và hỏi đáp. Python 3.12.14; Pandas 3.0.6; NumPy 2.5.4; Matplotlib 3.10.8; Seaborn 0.13.2. Codex hỗ trợ như khai báo trang 1. README chỉ cách cài môi trường và Restart/Run All; repo lưu các lần chỉnh sửa thực.

Repo: github.com/hoangduydz/CNTT219-LuongCongHoangDuy/tree/main/A2

[1] Đề A2-02: lms.tbd.edu.vn/mod/page/view.php?id=153568.
[2] Kaggle Titanic: kaggle.com/competitions/titanic/data.
[3] Quy tắc Kaggle: kaggle.com/competitions/titanic/rules.
[4] Pandas read_csv, crosstab, cut: pandas.pydata.org/docs/reference/ (tra cứu 14/10/2026).
[5] Notebook A2-02_Titanic_Kaggle891.ipynb và CSV có SHA256 ở trang 2.